TESIS · INFORME DE AVANCE · 5 DE OCTUBRE DE 2026

CAVA: organización multimodal de video largo por tópicos recurrentes

Estado de la implementación y resultados hasta EXP-030, con las corridas del pipeline sobre los documentales de la BBC y dos videos de prueba de YouTube.

EXP-020 a EXP-030 | 11 documentales · 730 clips | TVSum: 33/50 en curso

1 Introducción

En un video largo los temas vuelven. Un conflicto reaparece a lo largo de una película, un punto de agenda se retoma en otra parte de una reunión y una especie regresa en distintos tramos de un documental. La segmentación de escenas, el capitulado y el resumen automático entregan intervalos contiguos o una selección de fragmentos, así que un tema que vuelve termina partido en pedazos sin relación entre sí. Fusionar las modalidades en un solo vector agrava el problema, porque se pierde qué señal sostuvo cada decisión y una señal ausente se trata como si aportara información.

La pregunta de la tesis es cómo organizar y describir segmentos relacionados y no contiguos de un video largo, conservando la evidencia de cada señal y produciendo versiones distintas del contenido. La hipótesis general es que el consenso entre decisiones independientes (con abstención y enlace promedio) supera tanto a la fusión de representaciones como a una partición contigua.

- OE1: integrar señales visuales, de diálogo, de voz y descripciones de un VLM. H1 plantea que la señal acústica identifica al hablante mejor que la visual o la textual.
- OE2: construir mapas de tópicos por votos, quórum, abstención y enlace promedio. H2 (películas) y H3 (reuniones y documentales) los comparan con fusión y con partición contigua.
- OE3: etiquetar tópicos y propagar nombres de personajes sin perder precisión (H4).
- OE4: generar versiones por perfil (capítulos, recap, highlights, hilos) dentro de un presupuesto de duración.
- OE5: medir el alcance narrativo con una revisión ciega de enlaces (H5).

Fuera de alcance: CAVA no afirma entender la trama ni identificar personajes de forma fiable, y no evalúa la calidad subjetiva de las versiones. En películas, "mismo tópico" se aproxima con personajes compartidos (Jaccard del reparto).

2 Estado del arte

Cada línea de trabajo resuelve una parte del problema. Ninguna agrupa segmentos no contiguos y a la vez conserva la procedencia de cada señal.

ÁREA	TRABAJOS	QUÉ ENTREGA	QUÉ LE FALTA PARA ESTE PROBLEMA
Resumen de video	SumMe, TVSum, A2Summ	Fragmentos importantes	No agrupa lo que regresa ni explica por qué se eligió cada fragmento
Escenas y capítulos	TransNetV2, ShotCoL, SCRL, BaSSL, LGSS, MEGA, VidChapters-7M	Fronteras e intervalos contiguos	Un tema que vuelve queda en capítulos separados
Tópicos en texto y reuniones	TextTiling, Galley et al. 2003, corpus AMI	Segmentación temática del discurso	Contigua y solo textual
Identidad de hablante	x-vectors, WavLM, pyannote, VoxConverse	Quién habla y cuándo	Dice quién habla; el tema queda fuera

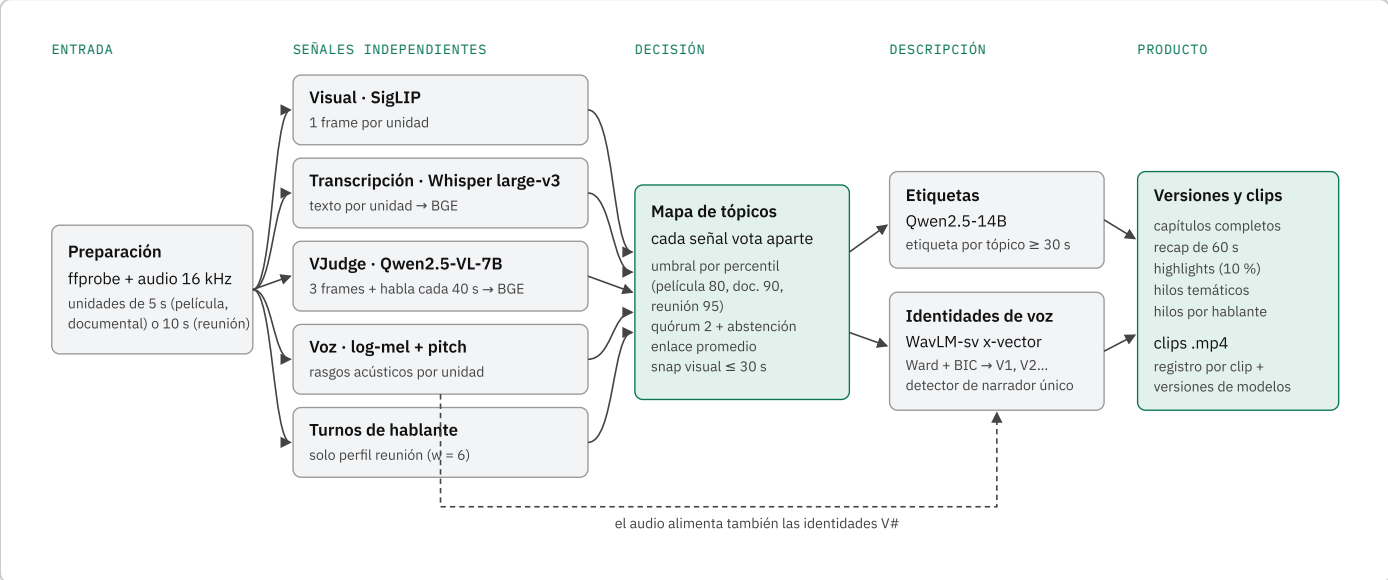
ÁREA	TRABAJOS	QUÉ ENTREGA	QUÉ LE FALTA PARA ESTE PROBLEMA
Fusión y consenso	Baltrušaitis et al., Strehl y Ghosh, Fred y Jain	Fusión temprana o tardía; consenso de clusterings	La fusión oculta la evidencia; el consenso no se ha aplicado a video largo con abstención
VLMs como instrumento	SigLIP, Qwen2.5-VL, Scene-VLM, Whisper, BGE	Embeddings, descripciones y transcripción	Describen el contenido; la estructura la tiene que decidir otro componente

Antecedentes del grupo: A2Summ-X mejoró el F1 en TVSum con una rama textual (ΔF1 = 0.033, p = 0.014, N = 25) y mostró que en la fusión una señal domina a las demás, lo que llevó a mantener decisiones separadas en CAVA. SegLoop llegó a F1 53.19 y AP 55.33 en fronteras de escena con un ensamble; esas métricas no miden recurrencia temática.

---

3 Estado de la implementación

El pipeline completo está implementado y corre de punta a punta sobre un video: desde el archivo de entrada hasta los clips de cada versión. Cada etapa guarda su avance, así que una corrida interrumpida retoma donde quedó. El diagrama muestra las etapas en el orden en que se ejecutan.



Cada señal compara pares de unidades y vota "mismo tópico" solo si supera su propio percentil. Si una señal no tiene datos (una unidad sin habla, por ejemplo), se abstiene en vez de votar en contra. Hacen falta dos votos para unir unidades. El mapa resultante guarda qué señales votaron cada enlace, y con eso cada tópico y cada retorno quedan trazables.

Cada corrida deja además un registro pensado para entrenamiento posterior: las versiones exactas de los modelos usados y una fila por clip con su tópico, duración y posición. Las recompensas se calculan fuera del pipeline (EXP-031), así que el GT nunca toca el producto.

---

4 Resultados experimentales

0.413
M_local en documentales BBC de confirmación; el acuerdo entre humanos llega a 0.662

0.249 → 0.635
ARI de identidades de hablante en VoxConverse test al pasar a x-vectors WavLM

11/11
episodios BBC con versiones dentro de presupuesto; 730 clips

33/50
videos TVSum procesados con la versión final del pipeline al cierre del informe

Todas las comparaciones usan el video como unidad: diferencia pareada por video y z = media / error estándar, con aceptación si z > 2. Las hipótesis se registraron antes de correr la evaluación de confirmación.

EXP.	PREGUNTA	RESULTADO CLAVE	VEREDICTO
020a	¿La voz identifica hablantes en AMI mejor que lo visual?	AUC 0.72 frente a 0.56; réplica en reuniones nuevas +0.188 (z 12.1)	validado
020b	Mapa de tópicos en reuniones AMI	Frente a contiguo −0.155 (z −2.9): salen 18 a 20 tópicos donde hay 7	no validado
021	Granularidad por perfil de contenido	No inferior a contiguo (z −1.6); supera a fusión +0.089 (z 3.4)	parcial
022	Regla para contar hablantes	Ward + BIC: ARI 0.297 frente a 0.080 visual; BIC mejor que silueta (z 3.5)	validado
023	Votante de turnos de habla	MCC 0.234; supera a voz (z 2.32) y fusión (z 3.52), empata con contiguo (z 0.27)	parcial
024	Pesos de voto aprendidos	+0.031 ± 0.026 (z 1.22)	no validado
025	Documentales BBC	M_local 0.413; frente a contiguo +0.174 (z 6.11), frente a fusión +0.126 (z 7.41). F1 de fronteras: visual sola 0.48, CAVA 0.40	validado
026	Voz con un solo narrador	Error reducido +0.89 (z 2.29), pero quedan 5.7 grupos efectivos en vez de 1	alcance limitado
027	Ajuste de fronteras a cortes visuales (91 películas)	M_local 0.226 → 0.317 (z 26.6); F1 0.434 → 0.488. La visual sola sigue en 0.535	validado
028	x-vector WavLM frente a rasgos de voz	VoxConverse AUC 0.735 → 0.962, ARI 0.249 → 0.635; AMI ARI 0.286 → 0.731	validado
029	Detector de un solo hablante	Error en K +0.155 (z 2.60), sin falsos positivos en AMI; en BBC detecta 0 de 11	acotado
030	Parakeet en lugar de Whisper	Más habla perdida (0.060 frente a 0.015) y BBC −0.022; se queda Whisper	no validado

En curso: EXP-031 compara cada clip con la importancia humana de TVSum (recompensa por clip con nulos aleatorio y uniforme), y EXP-032 compara los tópicos con los capítulos del autor en VidChapters (40 videos). El primer lanzamiento de EXP-032 falló por falta de memoria al caer en una partición MIG de la GPU. Los trabajos se reenviaron pidiendo GPU completa y están en cola.

5 Pruebas sobre videos

BBC Planet Earth, 11 episodios (perfil documental)

Son 540 minutos de audio en italiano, unos 49 por episodio, en unidades de 5 s (6 501 en total). Los episodios 01 a 04 se usaron para desarrollo y del 05 al 11 para confirmación.

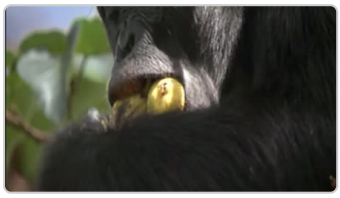
EP.	MIN	UNIDADES	TÓPICOS	CON RETORNO	GRUPOS DE VOZ	CLIPS
01	49.3	591	32	15	4	62
02	48.1	577	34	13	5	66
03	49.3	592	33	13	4	65
04	49.0	589	34	14	5	67
05	49.2	591	32	15	7	67
06	49.3	592	38	12	8	67
07	49.3	592	34	14	4	70
08	49.2	591	34	12	5	69
09	49.2	591	37	10	4	65
10	48.9	587	32	13	7	62
11	49.0	588	35	13	5	70

Cada episodio tiene un solo narrador, pero el pipeline encuentra entre 4 y 8 grupos de voz. Estos grupos responden a la escena acústica (música, ambiente) y no a personas, y el detector de narrador único todavía no se activa en BBC. Con un filtro de habla Parakeet ∩ Whisper, el detector reconoce un narrador en 10 de 11 episodios (resultado secundario de EXP-030, sin GT).

`ep. 05 · tópico 13` Higueras como fuente de alimento en la selva



13:27 · primer tramo



42:27 · retorno 29 min después

`ep. 05 · tópico 11` Crecimiento de plantas y supervivencia de chimpancés



8:57 · primer tramo



45:12 · retorno

El tópico 13 une dos tramos separados por media hora donde se ve la misma fuente de alimento. En el 11 el primer tramo muestra el dosel, sin chimpancés, porque la etiqueta resume el tópico entero y un tramo suelto puede verse distinto.

Resumen de Avengers: Endgame (YouTube, 35:11)

Este video tiene un solo narrador que cuenta la película sobre sus imágenes, un caso cercano al documental. Se procesó con el pipeline completo (perfil documental) en 9 minutos de GPU.

Unidades de 5 s	422	Tópicos (nivel por defecto)	28, 8 con retorno
Tópicos (nivel fino)	71, 1 con retorno	Grupos de voz	1 (V1, 100 %)
Versiones generadas	7	Clips cortados	47
Recap	60 s	Highlights (10 %)	210 s de 211
Capítulos completos	28 clips, 22.6 min	Frames extraídos	581

`tópico 24` Recuperación de las Gemas del Infinito y sus consecuencias



19:27 · primer tramo



30:47 · cuarto tramo

`tópico 6` Planes para enfrentar a Thanos y recuperar las gemas



4:47 · primer tramo



13:17 · segundo de 6 tramos

El tópico 6 es el más largo (535 s en 6 tramos) y junta escenas que se ven muy distintas, como muestran estos dos frames. Un retorno indica que un tema se retoma en el video; no debe presentarse como un hilo de trama reconocido.

The Wild Project #384 con Luisito Comunica (YouTube, 2:59:27)

Es una conversación de tres horas entre dos personas en un set fijo. Aquí se corrió el demo liviano (Whisper tiny y SigLIP en ventanas de 10 s), no el pipeline completo. No hay GT, así que estas cifras describen la salida sin medir su precisión.

Ventanas de 10 s	1 077	Segmentos ASR / palabras	4 022 / 35 932
Cortes de consenso	78 (79 tramos)	Duración de tramos	mediana 1:30, media 2:16
Tramo más corto / más largo	0:20 / 10:00	Cortes propuestos texto / visual	172 / 189
Coinciden a ±10 s / ±20 s	73 / 95	Grupos temáticos	103
Grupos no contiguos	18	Sin tópico / a revisar	19 / 13



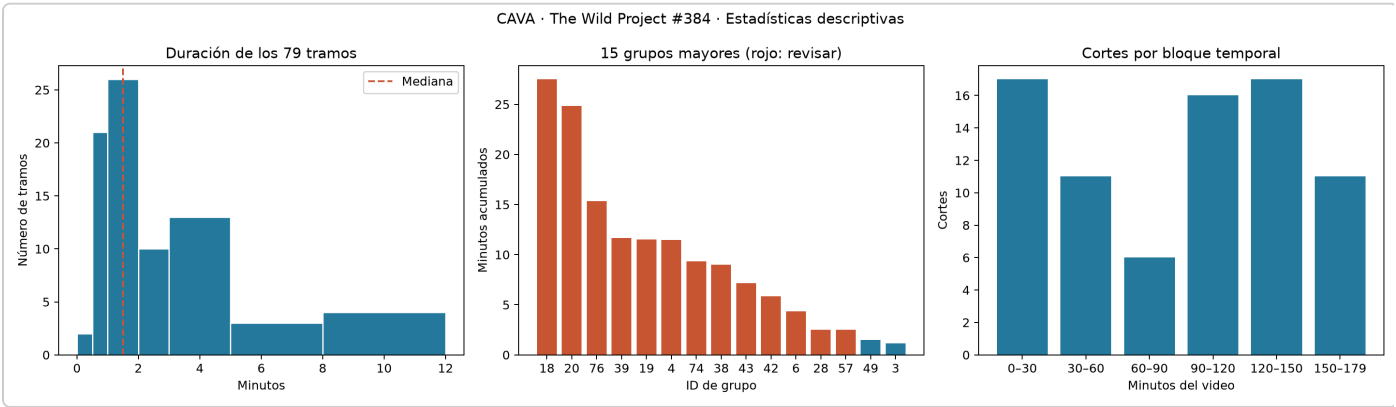
3:35 · tras el primer corte



50:05



2:30:05 · cambio de formato



Duración de tramos, grupos mayores (en rojo los marcados para revisión) y cortes por bloque de 30 min

En este formato la imagen casi no cambia, así que la mayor parte de la estructura la aporta el texto. Los 13 grupos marcados para revisión cubren el 79.7 % del video y el mayor suma 27.5 minutos, lo que indica que en una charla larga los grupos salen demasiado amplios. El siguiente paso para este video es correrlo con el pipeline completo y el perfil de reunión.

6 Limitaciones y próximos pasos

- En BBC y en películas la señal visual sola sigue marcando mejores fronteras que CAVA (F1 0.48 frente a 0.40 en BBC). El ajuste a cortes visuales cierra parte de la brecha, pero no toda.
- En reuniones AMI el mapa no supera a la partición contigua; se fragmenta en más tópicos de los que hay.
- Con un narrador, los grupos de voz responden al ambiente sonoro. El cuello de botella está en la detección de habla.
- Los retornos son temas que se retoman y las etiquetas son descripciones del modelo de 14B; ninguna de las dos cosas prueba comprensión de la trama.
- Pendiente: terminar las corridas con la versión final del pipeline (TVSum y VidChapters), calcular EXP-031 y EXP-032 y pasar los resultados a la tesis.